

Pipeline 1 - Data Management

- S'ha considerat una interrupció no planejada aquella que a *AMOS* té *kind* del tipus '**AircraftOnGround**' o '**Safety**' o '**Delay**'. Consultat amb els tutors.
- Només s'han considerat les interrupcions d'operacions causades pel subsistema **3453**, atès que és del qual en tenim valor. Considerem que no tindria sentit predir interrupcions d'altres subsistemes sense tenir-ne dades.
- Per mantenir aquelles files d'*AMOS* per les quals no tenim dades de *DW* però que poden afectar-les, fem en un *full join* (e.g. a *DW* hi ha 16/6/12, però no 17/6/12 per un aircraft, però a *AMOS* hi ha una *unscheduledOI* per 17/6/12 que sí que afectaria el 16/6/12). Després d'etiquetar, les eliminem.
- S'ha implementat una funció de transformació a matriu, però com que per entrenar el model es fa servir un *dataframe*, no s'usa el format matriu. Sí que la guardem en un arxiu *txt*.

Pipeline 2 - Data Analysis

- S'ha inclòs com a feature el *aircraftid*, de manera que si un aircraft en concret és més propens a tenir una *unscheduledOI*, el classificador ho pugui aprendre. Això ho podem fer pel fet que tenim pocs aircraftids diferents.
- En canvi, amb *timeid* no seria una bona pràctica, ja que el model acabaria sobreajustant i aprenent els mappings de (*aircraftid,timeid*) a *label* directament, ja que tenim moltes dates diferents.
- Un cop entrenat el model, en els nostres ordinadors hem tingut problemes per guardar-lo (error amb I&O del mateix *Windows*). És per això que està la línia de guardar comentada. Per usar el model a la *pipeline 3* el retornem.
- En vista de les mètriques del model, s'ha decidit que no cal balancejar les classes, ja que obtenim molt bon *recall* per les dues classes (>85%).

Pipeline 3 - Run-Time Classifier

- Com que es tracta d'un classificador en temps d'execució, hem pensat que la proposta més adient és que l'usuari vagi entrant un a un els parells (*aircraftid,timeid*).
- S'utilitza una *queryCache* per tal d'estalviar càlculs si hi ha entrades repetides i per poder mostrar a l'usuari totes les seves consultes quan marxi.

General → L'execució conjunta de les pipelines es pot consultar a l'arxiu *main.py*

